

Naive_Bayes_A

August 31, 2021

1 Bài toán phân loại sử dụng Naive Bayes

Mục tiêu:

- Xây dựng được mô hình nb sử dụng thư viện sklearn.
- Ứng dụng, hiểu cách áp dụng mô hình nb vào giải quyết bài toán thực tế (vd: phân loại văn bản)
- Sử dụng độ đo Accuracy để làm độ đo đánh giá chất lượng mô hình.

Vấn đề: - Có một tập các văn bản dạng text không có nhãn, làm sao để biết văn bản này là thuộc về thể loại nào, pháp luật, đời sống, văn học, thể thao ... - => Xây dựng mô hình học máy có thể phân loại các thể loại của văn bản chỉ dựa trên nội dung.

Dữ liệu: - Có tập các văn bản và nhãn tương ứng của từng văn bản trong một khoảng thời gian
- Tập các nhãn - 10 nhãn văn bản: > Giải trí, Khoa học - Công nghệ, Kinh tế, Pháp luật, Sức khỏe, Thể thao, Thời sự, Tin khác, Độc giả, Đời sống - Xã hội - Ví dụ văn bản nhãn **thể thao**:
> “Dân_trí Real Madrid đã dẫn trước trong cả trận đấu , nhưng họ vẫn phải chấp_nhận bị Dortmund cầm hòa 2-2 ở Bernabeu . Real Madrid chấp_nhận đứng thứ_hai ở bảng F Champions League ...”

Bài toán: - Input: tập các từ trong văn bản 1 mẫu dữ liệu $X = [x_1, x_2, \dots, x_n]$ - Output: nhãn y là 1 trong 10 nhãn trên

2 Nội dung thực hành

1. Nếu sử dụng GColab, cần kết nối với server và Gdrive(nếu sử dụng dữ liệu trong drive)

```
[9]: from google.colab import drive
drive.mount('/content/drive')
```

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).

```
[10]: cd /content/drive/MyDrive/NB_practice/1. Practice
```

/content/drive/MyDrive/NB_practice/1. Practice

2. Import các thư viện cần thiết, cài thêm một số thư viện chưa sẵn có

```
[11]: # Cài đặt thư viện xử lý ngôn ngữ cho tiếng Việt!  
!pip install pyvi
```

```
Requirement already satisfied: pyvi in /usr/local/lib/python3.7/dist-packages  
(0.1.1)  
Requirement already satisfied: sklearn-crfsuite in  
/usr/local/lib/python3.7/dist-packages (from pyvi) (0.3.6)  
Requirement already satisfied: scikit-learn in /usr/local/lib/python3.7/dist-  
packages (from pyvi) (0.22.2.post1)  
Requirement already satisfied: numpy>=1.11.0 in /usr/local/lib/python3.7/dist-  
packages (from scikit-learn->pyvi) (1.19.5)  
Requirement already satisfied: scipy>=0.17.0 in /usr/local/lib/python3.7/dist-  
packages (from scikit-learn->pyvi) (1.4.1)  
Requirement already satisfied: joblib>=0.11 in /usr/local/lib/python3.7/dist-  
packages (from scikit-learn->pyvi) (1.0.1)  
Requirement already satisfied: tabulate in /usr/local/lib/python3.7/dist-  
packages (from sklearn-crfsuite->pyvi) (0.8.9)  
Requirement already satisfied: tqdm>=2.0 in /usr/local/lib/python3.7/dist-  
packages (from sklearn-crfsuite->pyvi) (4.62.0)  
Requirement already satisfied: python-crfsuite>=0.8.3 in  
/usr/local/lib/python3.7/dist-packages (from sklearn-crfsuite->pyvi) (0.9.7)  
Requirement already satisfied: six in /usr/local/lib/python3.7/dist-packages  
(from sklearn-crfsuite->pyvi) (1.15.0)
```

```
[12]: import matplotlib.pyplot as plt  
import numpy as np  
  
#from sklearn.datasets import load_files  
from pyvi import ViTokenizer # Tách từ tiếng Việt  
  
import sklearn.naive_bayes as naive_bayes  
from sklearn.datasets import load_files  
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer  
from sklearn.feature_extraction.text import TfidfTransformer  
from sklearn.model_selection import train_test_split, GridSearchCV  
from sklearn.pipeline import Pipeline  
from sklearn.model_selection import ShuffleSplit  
from sklearn.model_selection import learning_curve  
  
%matplotlib inline
```

3. Load dữ liệu từ thư mục đã crawl từ trước

Cấu trúc thư mục như sau - data/news_1135/ - Kinh tế: - bài báo 1.txt - bài báo 2.txt
- Pháp luật - bài báo 3.txt - bài báo 4.txt

```
[13]: data_train = load_files(container_path="data/news_1135/", encoding="utf-8")

print(data_train filenames)
print()

print("Tong so file: {}".format( len(data_train.filenames)))
print("Danh sách nhãn và id tương ứng: ", [(idx, name) for idx, name in
↪ enumerate(data_train.target_names)] )
```

```
['data/news_1135/Thể thao/2e62de81ade8318f66cc740f5ede5607ea1bf002.txt'
'data/news_1135/Thể thao/f9bd156031140a7db52ae51de4561f234a0eb277.txt'
'data/news_1135/Thể thao/aeeb3b3b0dfc936de928f0b004259aca70aa4efa.txt'
'data/news_1135/Thể thao/7787f359bd1efeeee382a8077a7725e03b01e3a53.txt'
'data/news_1135/Thể thao/cf967f8831bf7102304dce974b370ad26991fc65.txt'
'data/news_1135/Thể thao/92169a7c47b1661f24aa1651f418490049c95cac.txt'
'data/news_1135/Sức khỏe/b6c8c39ad177edc5b6b7509f7c21eebe21631970.txt'
'data/news_1135/Thể thao/f206d5fcf67b820dbe314e7d152f5b2d181e38c1.txt'
'data/news_1135/Sức khỏe/f6b9942c0ab5548ede99940d6ed1dd6fd3b36dbe.txt'
'data/news_1135/Sức khỏe/24181828a2a95af5c40505922a64bb6fb177e266.txt'
'data/news_1135/Thể thao/4075a388765339747f4e5961a0a34a9bcf953413.txt'
'data/news_1135/Sức khỏe/774c529f2193777355fa684446dd195f79391d9c.txt'
'data/news_1135/Sức khỏe/0fb06f1f48bba02087ae57d6625573d9e1d2e77a.txt'
'data/news_1135/Thể thao/86def9a683b6d9c5f3aea66f6cb1f231c5938aa5.txt'
'data/news_1135/Sức khỏe/f44b40ac0aa93d26119c0412779ba22ea821143a.txt'
'data/news_1135/Thể thao/d388bd12f023a7fc0738908960f96f3e462fd7ef.txt'
'data/news_1135/Thể thao/7abca41c1b1dd6ca1dd530086c3a4008052ac68e.txt'
'data/news_1135/Thể thao/fbad9127404d5aca3ce9e3239ad765e78887c740.txt'
'data/news_1135/Thể thao/fbea98be67e128e89707e0e87031005bd7f1c45c.txt'
'data/news_1135/Thể thao/253edbad0fe23840ea12d26e6fab4ef2c21a8410.txt'
'data/news_1135/Thể thao/45888a588888498ac6feb72251c24253b1f1e688.txt'
'data/news_1135/Thể thao/0eda2f40ec17ed8ff6d9ccf336cda9bbd708df01.txt'
'data/news_1135/Thể thao/632fe3f5cc84b069b2d7066049ec6b81ea8bab0d.txt'
'data/news_1135/Thể thao/0f22a1b40c529312ab6c42cd5e2142f8fac31347.txt'
'data/news_1135/Thể thao/987a079f10898d1e379950f0392bce3777386864.txt'
'data/news_1135/Sức khỏe/2f2584a62e860201b35c849e4a58fa168c6a3fa7.txt'
'data/news_1135/Thể thao/9a65dc71b7b835a75163fdf790d8ddfef5c20ece.txt'
'data/news_1135/Thể thao/9c01b8a7b2ab5bc9bc3b4bb3303374f5304e6ac9.txt'
'data/news_1135/Thể thao/60a22ade184347e27d8502df77059e93509070f2.txt'
'data/news_1135/Thể thao/730c83e51f0037a36d8f1c604e3090a2a593df74.txt'
'data/news_1135/Sức khỏe/d09f6be09f1445e433ec96a7dcbbd799c5cb6d07.txt'
'data/news_1135/Thể thao/3af765d616bccb98ce49577e1823ad80f73e9a0b.txt'
'data/news_1135/Thể thao/99395ae454298a82f29e88d17ae03c6eee87565c.txt'
'data/news_1135/Thể thao/b08e07b80dccef34f3873ac58a7264bbb67a8c01.txt'
'data/news_1135/Sức khỏe/401240c3b4d4586cbd0011ae707f4fc48ecdb878.txt'
'data/news_1135/Sức khỏe/36153c653292d0206aabaa9d8b9af5c08c74a7bd.txt'
'data/news_1135/Thể thao/2a36fb55beed9e6a32bfda5945774dbaf062a0ad.txt'
'data/news_1135/Sức khỏe/2118468a95b418b33ab9aae031c932e80489c692.txt']
```

'data/news_1135/Thẻ thao/0f26e72618f188477a87f84f8d0eea170fe7ebcf.txt'
'data/news_1135/Thẻ thao/9e1ddb7990519964503c93a84afc3710a7d1a633.txt'
'data/news_1135/Thẻ thao/3148e19f05b147d37f101724b293766af1e186a0.txt'
'data/news_1135/Thẻ thao/7d92472bc9c6318ffb7f7f010b6a720bf5b8ac7a.txt'
'data/news_1135/Thẻ thao/958117b6b2e94e1c9ecf557ca8b2019b4113e128.txt'
'data/news_1135/Thẻ thao/3f26668f3379443b3803c5b1ce3a29c3c26e18d3.txt'
'data/news_1135/Thẻ thao/f76382aa75f9f2a8888a9f3940e7c1bea1d5df58.txt'
'data/news_1135/Sức khỏe/6f51cac4d6f5547fe0ea51afa2e1803c78653992.txt'
'data/news_1135/Thẻ thao/82eab1911c8bec054c3e36129292f2bd8e379b02.txt'
'data/news_1135/Thẻ thao/ed6e4fc47fbb362d9a46a02e789e1f45fc4a34d6.txt'
'data/news_1135/Thẻ thao/f241b1ba68084e17728870d16bcb8bbdd9e37708.txt'
'data/news_1135/Thẻ thao/7a2a3c443fdb2599b652e61dae161b75f8b3ee.txt'
'data/news_1135/Thẻ thao/502411b89d6271fa323337007d55e5c078855299.txt'
'data/news_1135/Thẻ thao/dadf780f3a8d2702b6f6e565b6436f5666cdd8ef.txt'
'data/news_1135/Thời sự/163dd787e4c052696a6977468a209e62ca2df48a.txt'
'data/news_1135/Sức khỏe/3d7399de5bf9a54634c3ccbc0456de0805f172bb.txt'
'data/news_1135/Thẻ thao/5ee1dd38f31f2c61aa851907eddbbc3d84dbad1b4.txt'
'data/news_1135/Thẻ thao/42dc335bdd59d6b3b7fab65c6515311daadf6f50.txt'
'data/news_1135/Thời sự/085c6cc09343ecd67a001775c0eb25fa6efa60e7.txt'
'data/news_1135/Sức khỏe/457e4d1405b5be05fc32b391c704882eb1b386cc.txt'
'data/news_1135/Thẻ thao/fa9e0baf024a891963eee3faa0a7a9f9207d56e8.txt'
'data/news_1135/Sức khỏe/b986b5d131c994d3c89dae6a1b536a08d1e57fe6.txt'
'data/news_1135/Thẻ thao/07a14cd96285d73e4623d20d2f1d4d6e53a35eaa.txt'
'data/news_1135/Sức khỏe/0d20684ca0b0bbfdd2acf2c9afaceb0b0fb76706.txt'
'data/news_1135/Thẻ thao/16f102915e67794763026b09ec525436484689eb.txt'
'data/news_1135/Thẻ thao/d4a987e3b961ed2040e91a801a522cc2f3acd7c8.txt'
'data/news_1135/Sức khỏe/e42f150a7ddc1d35bd87cbf19c5ccacdd454dd5a.txt'
'data/news_1135/Sức khỏe/cde732a56f46549a19ff03fc69b6054fb603686c.txt'
'data/news_1135/Sức khỏe/fa5f09835c09ca234065cb8020ea2c8a49094516.txt'
'data/news_1135/Sức khỏe/5bd037a339c8311bce9c01aa8cd49a0ad9a68992.txt'
'data/news_1135/Thẻ thao/a4020c92b72f032b67e84f6e4f928ce3a1061b28.txt'
'data/news_1135/Sức khỏe/88829ba824346011c1bf781a837a0d9419a72f37.txt'
'data/news_1135/Sức khỏe/3044900ba3cc1f3521ecb5dc9bb5e4eb403335d0.txt'
'data/news_1135/Thẻ thao/5c6f96df4734f383b1ad906c0175cf0442e2298b.txt'
'data/news_1135/Thẻ thao/25100114c5bfe2e54536a46fda3079b4985d7155.txt'
'data/news_1135/Sức khỏe/4b801eaac7f85cb09c675344b5343726830f9f2f.txt'
'data/news_1135/Sức khỏe/64e45d56781a71c9931fc0c3cab76c9dc66a7712.txt'
'data/news_1135/Sức khỏe/e0b3dcfaca2631b25ac5569b7ba448d28483a00c.txt'
'data/news_1135/Sức khỏe/d6461b7e660f4ae34b1b678d2a0884d95404049d.txt'
'data/news_1135/Thẻ thao/9da3289d656cf62d0fed69079f94faa05a5a4482.txt'
'data/news_1135/Thẻ thao/374528d301abac72c4d3001ae9af3c2e09a3f601.txt'
'data/news_1135/Sức khỏe/40f4ddfaa16f6f4edf0e5fd5bde6fdacac8de9d9.txt'
'data/news_1135/Thẻ thao/a8345d1b121833e1265e6ca8fc3e429b7dc666b8.txt'
'data/news_1135/Thẻ thao/badd7a9bd190a7152b579f10908a4eb633f3e0ce.txt'
'data/news_1135/Sức khỏe/cfbf42dd5d2d70be830e47d38b899f2fa221e8c9.txt'
'data/news_1135/Thẻ thao/cc8d939df94a5b65003da24224fdc95dbcbfcb7d.txt'
'data/news_1135/Thẻ thao/145318737e5ffee85a10ba03f018b87d1b62f308.txt'
'data/news_1135/Sức khỏe/cb4f08fa848f837ed61d55e72089c067a53c458d.txt'

'data/news_1135/The thao/417a06dd91a872fb0f7f63628f5944a2e3483fb7.txt'
'data/news_1135/The thao/983b4e49ed8330dd6b01e1330f79e34d25d0e0c5.txt'
'data/news_1135/The thao/557655d1792ffdfac66452534f5b2d98877b7c0.txt'
'data/news_1135/The thao/1e8cc19c72ecb7455b479849e4ce5582c142e944.txt'
'data/news_1135/The thao/c0469a82c5a7b508203777debc66ac46bbc70ee0.txt'
'data/news_1135/The thao/6537915f28358e9a5f58d18d20c291a178ec0da9.txt'
'data/news_1135/The thao/9b11e477ca23707cb5b5ad8e200dd9e5e4d7479f.txt'
'data/news_1135/The thao/45890a487b6aabf3a3d37f238ecfd858fc1362d4.txt'
'data/news_1135/Sức khỏe/95bc031af3cbacf06c185bee36f851957002e6bd.txt'
'data/news_1135/Sức khỏe/35a541674a6bb6c2c847db3650bddfa9b652cc02.txt'
'data/news_1135/Sức khỏe/6210261836c16928680709765bf52173c9f43dcd.txt'
'data/news_1135/The thao/7c4e2c0d15cf600e6b60d4cd195d89ee0eb3e408.txt'
'data/news_1135/The thao/f8826e003af6a07977401eb85ea138f8431fef50.txt'
'data/news_1135/Sức khỏe/4187c4a1d528fd9ea4630d2709229df0b0d09c3d.txt'
'data/news_1135/The thao/90688380f62ff0054e161667e09f42cad2a009e0.txt'
'data/news_1135/Sức khỏe/b9fd222c27783e7fa9d04526138db16299e5894a.txt'
'data/news_1135/The thao/97b5fbc82e26be4a3b372b50f73d180d37e21bb9.txt'
'data/news_1135/Thời sự/1685c22515a25fba9cb08982400d44bb0ed2b5ec.txt'
'data/news_1135/The thao/6c07fd6ba0e30fd5e60ad7dc96c479561a9f6041.txt'
'data/news_1135/The thao/9a47041acdd07e1d1ed71d54972dc792a1eb79ae.txt'
'data/news_1135/Sức khỏe/ee0f1e4d1398774ed1c7649d97edd33d847b0056.txt'
'data/news_1135/The thao/8dc8df2d734a56b6b469bf280ac94a3469290df6.txt'
'data/news_1135/Sức khỏe/078192445fcfa9f6ad7966d9bb096d4538ca3e27.txt'
'data/news_1135/Sức khỏe/db6afde480374f121ec92c863a8d5a45906d7128.txt'
'data/news_1135/The thao/78482cc264a62bfec675ee08927d65d522ec7ecf.txt'
'data/news_1135/The thao/fe1ff0f86a7e6b82ad69ab8cd029961268ca3b0f.txt'
'data/news_1135/Sức khỏe/b361fb7f77979922f4bbcf9c9c8f7cee67c3b94.txt'
'data/news_1135/Sức khỏe/2541b0f8349c824e1fb19b2150d71a88d0be5cfc.txt'
'data/news_1135/The thao/6a5ce046e5e47383ee79984a4145bef9ed23a24d.txt'
'data/news_1135/The thao/0c28b82392288de2c9834033383d665e9873317c.txt'
'data/news_1135/Thời sự/067759e9ff11ce9ce15f1268cbb0b51db507cfe4.txt'
'data/news_1135/Thời sự/0e0f38a472c34ba84ccb56d740fab4ee61e0242e.txt'
'data/news_1135/The thao/45e9d3aaf0a737ba61ce859ca22b78efa063ec74.txt'
'data/news_1135/The thao/f20ae72e0c13dc72b4eda7cbf6f8d9ff7d06c099.txt'
'data/news_1135/The thao/dba4bca57e2466fcb585e0690bf5c9c616af755b.txt'
'data/news_1135/The thao/349d3928c3f2b45680305dec2d71fccef49680a9.txt'
'data/news_1135/Sức khỏe/0c793f78b653ec265aa155f662a24ced5df9102b.txt'
'data/news_1135/The thao/2ace96fb4845fd83a1ebc1da6102d8c99cc0af79.txt'
'data/news_1135/The thao/72d833f05d8ff6ac2e9391f8891f69518ba1a264.txt'
'data/news_1135/The thao/f9ee38654e124da98fa0481a9de25fb87f39a8d0.txt'
'data/news_1135/Thời sự/05b1594fb5dcab9374de9d1728e31abd4040a91a.txt'
'data/news_1135/Sức khỏe/c82b3d1de545896821e672e0dcdd133ce9d7c506.txt'
'data/news_1135/The thao/4a1d69a6252464ea63fba507c4c10785c2cdf8ec.txt'
'data/news_1135/Sức khỏe/065cce8fbcdcb7df6941f23f515874f868ed501a.txt'
'data/news_1135/The thao/2bb8253b9960a705b81a9be46d37723f98a86c41.txt'
'data/news_1135/The thao/2d4a4181650a41cadd32d343f1e40ae02fedceb4.txt'
'data/news_1135/Sức khỏe/ff31b022e9694233e440ddcbce849c4f6a6b06e5.txt'
'data/news_1135/Sức khỏe/bfd048f90b73b4fa7b520bd8147844b6e9d87f28.txt'

'data/news_1135/Sức khỏe/be5e56ec476497721af041f6ec1f95df8f4e0046.txt'
'data/news_1135/Thể thao/1d888304d2cb930bb1aefc7da58483fe6e1e208f.txt'
'data/news_1135/Thời sự/186d19e79ffef4e039e5fd01090af06f5beb6cc0.txt'
'data/news_1135/Sức khỏe/492deb451fbb48e185a9adb0ece86f24721f1f3a.txt'
'data/news_1135/Thể thao/10b0aca26de4519e692860f651b2c72753c612b7.txt'
'data/news_1135/Thể thao/36d8f1e9a630a339b20ac2a1823cac154da4380e.txt'
'data/news_1135/Thể thao/6ca63d3017d501b65dc8c438f2b9f0cf110a5a40.txt'
'data/news_1135/Thể thao/ce972369134108f061b52e854de4c78a6dc24121.txt'
'data/news_1135/Thời sự/19d1394559552a4656fe735d26eeb214a0195a1e.txt'
'data/news_1135/Sức khỏe/1e040b866160284a0c17adda24fce76a89a6a18a.txt'
'data/news_1135/Sức khỏe/fe60e2173b2aef20ee748633081155b48ff6c639.txt'
'data/news_1135/Thể thao/1c9c73cacf403879f7928e12190727f2ad02bab1.txt'
'data/news_1135/Thể thao/5b4386ce4297a3aa86d56bffee5bc018ab95f124.txt'
'data/news_1135/Thể thao/feffbcecefc20e514a9da8039d282d32a62200b.txt'
'data/news_1135/Thể thao/b0220b94e499ed4503bb7486a718e2158781275d.txt'
'data/news_1135/Thể thao/dcc27fbd4a228f5c9cad4a41a393dca34b4d53c5.txt'
'data/news_1135/Thể thao/d44ec865976267f237f4c1d59571c2b97ea10b99.txt'
'data/news_1135/Thời sự/1a756cf2aa7609554271088b3008f9bcffdc664.txt'
'data/news_1135/Thể thao/28d529b8e87846824f76b5b3a77a76dc9eb7b207.txt'
'data/news_1135/Thể thao/e16ef8d6979ab0cc1c2a8694fe1aac543ee7a5af.txt'
'data/news_1135/Sức khỏe/27fc274930d84bb9fe38abbb762bc08bd27c1464.txt'
'data/news_1135/Thể thao/56534be658d47deff97096b81d1ab65a14413df9.txt'
'data/news_1135/Thể thao/37dc360305e4de93059d33def3cae49e023c5cf7.txt'
'data/news_1135/Sức khỏe/700030b85243dc4e6f0c2a57d5027771f471a067.txt'
'data/news_1135/Sức khỏe/d693533870ff41103fa37a5061581412726805d4.txt'
'data/news_1135/Sức khỏe/f76c14b3f643cb2494683bfb1758493f090abe85.txt'
'data/news_1135/Sức khỏe/0748735478fff881281d124207782e3ee26aa3ca.txt'
'data/news_1135/Thể thao/5a4f35112309b49fba4b40125c2ffc2e3bc17693.txt'
'data/news_1135/Thể thao/c8834cc95b390c39775d63b41368607b3721f74b.txt'
'data/news_1135/Sức khỏe/a6385c20ad0fdf602dcca708fc3f781840bf33d6.txt'
'data/news_1135/Thể thao/3b24f28b35d9a71e795f61740e3a70ae16d397fe.txt'
'data/news_1135/Thể thao/715fbb01ba82d76868e04c5288eb1b20e6ec1bc3.txt'
'data/news_1135/Thể thao/e7748744f2c8ed82e2dcbe610d6fc28e94b20912.txt'
'data/news_1135/Sức khỏe/3ecd612a90cf25f2bfbef6cd1b46774f24cbe13.txt'
'data/news_1135/Sức khỏe/796cdde1c2b062e43e414d1d6439ee23a69b16bd.txt'
'data/news_1135/Thể thao/72b3e7b65df0429ee2050ca715cbf421489cfd.txt'
'data/news_1135/Sức khỏe/ce639bd9974dee8cd7b3c2164e04f9336902d9e5.txt'
'data/news_1135/Thể thao/a1865d54915678d207630d9f2acaf20f5fa68d4b.txt'
'data/news_1135/Thể thao/b3894c28cc78c737a55f3ba1eb2cbc0f022a4315.txt'
'data/news_1135/Thể thao/6792c8c973fffd52c55a86a5a9abcf7a371932f.txt'
'data/news_1135/Sức khỏe/6faffd2aa03c8bebf5248117bc668a84c4aae4d4.txt'
'data/news_1135/Sức khỏe/62a5799ef50a9a47dcf17665e0516371593bdcb6.txt'
'data/news_1135/Thể thao/4cf051d705d4ac4914783e8fff3c3a6bde457446.txt'
'data/news_1135/Thể thao/a154b3b4f333739e85f847ded25fcf1d69270733.txt'
'data/news_1135/Thể thao/931ce0fdf286bf5fb3b1d034c9f5849d50ec56ae.txt'
'data/news_1135/Sức khỏe/65b86a10cb99c7863b9dffc5e19dfd09f6725308.txt'
'data/news_1135/Thể thao/d0766310fe33eb60c05419fefa44f439926b3431.txt'
'data/news_1135/Thể thao/66d8b419ac83e188849948205277510bdf2fce17.txt'

```
'data/news_1135/Thể thao/f14a79ea3c0e4f13afecde4513e3609a9771eb89.txt'
'data/news_1135/Sức khỏe/6b00807477375b0b34e03070c5fc11793610c4b5.txt'
'data/news_1135/Thể thao/a663ffdc3ceea4adde0056650ee5639b606fa0ff.txt'
'data/news_1135/Thể thao/7cc09b2a8417da8c0131dbd40d868dd33bf7fb23.txt'
'data/news_1135/Thể thao/d563d0fcdceae7a0b887ab8772866ba715d1723a.txt'
'data/news_1135/Thể thao/8f09e7eb2471b190110c15d66d40a685edfa60e5.txt'
'data/news_1135/Sức khỏe/633ba06b9f35be07e25606490e798c5f5117f3e3.txt'
'data/news_1135/Thể thao/bf151a48eb8fc6b7a608c62a59c1af39eecd6dc4.txt'
'data/news_1135/Thể thao/36b96dac2c27a51ed53f03a1278b552e546e83a7.txt'
'data/news_1135/Thể thao/150ddfc196fa92bd1e644b063a0811a7773c81c2.txt'
'data/news_1135/Thời sự/181b05896a852f8174b649611dae26ee4efba75f.txt'
'data/news_1135/Thể thao/ba45677ae82848b677ba7a2dc0d8ff4ba4ed0293.txt'
'data/news_1135/Thể thao/12abf8f4465a472cc44974cc63a4ca7d3306f9b8.txt'
'data/news_1135/Thể thao/4d1c211f6f982d2218b352599d0db45fb891ee03.txt'
'data/news_1135/Thể thao/8f40dd8e62eaeef67769c159913c6947dbe373bf1.txt'
'data/news_1135/Thời sự/0dba5e684e3293810cce1982f68e9b5f2b1ccdae.txt'
'data/news_1135/Thể thao/0bef1954a952989e45eb00b087a5316904bef238.txt'
'data/news_1135/Thể thao/0fece90b645144364fa1787922295c50cfaa47b5.txt'
'data/news_1135/Sức khỏe/53654b474430467045e427a76b986175a75d59ec.txt'
'data/news_1135/Thể thao/a1b1ed7aa618192e7a87d2b3be66aac34281bad2.txt'
'data/news_1135/Thể thao/145b46ca8dadf86190c652dbdf6f33b31688019e.txt'
'data/news_1135/Thời sự/00ffef50901b539f9039dca10fda248a313e44b3.txt'
'data/news_1135/Thể thao/b46d75fac8bd8deb728534ec8d74b90d3975dce5.txt'
'data/news_1135/Thời sự/01a77203cd131e050a0119b2b5e645db8df50746.txt'
'data/news_1135/Sức khỏe/81e40e473c417514b92a760eda88738d83bd2c3a.txt'
'data/news_1135/Thể thao/e72837ae1012b4f1caa841c3000cdc8c1cf176e1.txt'
'data/news_1135/Sức khỏe/daf0c96e1003b53a7b32add91c3138a3c9f57892.txt'
'data/news_1135/Thể thao/7adaf0c561796f2411340150f18417543ad4403c.txt'
'data/news_1135/Thể thao/21f577b9c57253e056e50ecb1e7936c6d1bc8bb4.txt'
'data/news_1135/Thể thao/0236f462de2beb1f9dcca27a747b57ffe5e54fc1.txt'
'data/news_1135/Thể thao/203ceba079147c5e7f69115298994e6b0405c8c7.txt'
'data/news_1135/Sức khỏe/7180ee66467f8a703ab4e1bd92e3da0efde8c662.txt'
'data/news_1135/Sức khỏe/43b45beb5f82fa0dcfc228bd78d287a26a251026.txt'
'data/news_1135/Thời sự/012332fa5d590a5287c1d1474badf0cde6e06ff4.txt'
'data/news_1135/Sức khỏe/24d8b5d4da12965376cc879458b201e7e6dc6c22.txt'
'data/news_1135/Thể thao/38f6ec7fc74ffa9e93bee2c6fbf809838fc5e02c.txt'
'data/news_1135/Thể thao/e78ef641b159653587e011d5929935b33e78c8d8.txt'
'data/news_1135/Sức khỏe/fcb50b8cc6048dc51090cb8f3f8c143f2c26a3d7.txt'
'data/news_1135/Thể thao/e3b6d4ddaf1052c883dee760426e7486e00d149c.txt'
'data/news_1135/Thể thao/531b4f65e28b6c6a29910d7b84c1ad17bf76717a.txt'
'data/news_1135/Sức khỏe/bd9a58eb28b071e6c0a51578d5b544699bae1ff7.txt'
'data/news_1135/Thể thao/b2ee48d1298e9ef247f81781add7f2892f54a2c5.txt']
```

Tong so file: 224

Danh sách nhãn và id tương ứng: [(0, 'Giải trí'), (1, 'Khoa học - Công nghệ'), (2, 'Kinh tế'), (3, 'Pháp luật'), (4, 'Sức khỏe'), (5, 'Thể thao'), (6, 'Thời sự')]

```
[14]: ### bài tập ###
# yêu cầu: Hiển thị nội dung, và nhãn của văn bản đầu tiên trong tập train.
# gợi ý: tự làm.
#####
# code

print('- Nội dung của văn bản đầu tiên:', data_train.data[0])
print()

print('- Nhan của văn bản đầu tiên:', end=' ')
print(data_train.target_names[0])

#####
```

- Nội dung của văn bản đầu tiên: Dân trí Sáng 5/12 , giải quần vợt các tay vợt xuất sắc Việt Nam - Cúp Vietravel 2016 đã chính thức khai mạc tại TP Vinh - Nghệ An . Tham dự giải hơn 30 tay vợt xuất sắc nhất của Liên đoàn quần vợt Việt Nam . Dự lễ khai mạc có ông Nguyễn Trọng Hổ - Vụ trưởng Vụ thể thao thành tích cao II ; Đoàn Quốc Cường - Trưởng bộ môn quần vợt Liên đoàn quần vợt Việt Nam ; Nguyễn Quốc Kỳ - Tổng Giám đốc Vietravel , Phó Chủ tịch kiêm Tổng thư ký Liên đoàn quần vợt Việt Nam cùng lãnh đạo tỉnh Nghệ An . Giải quần vợt các cây vợt xuất sắc Việt Nam - Cup Vietravel 2016 do Liên đoàn Quần vợt Việt Nam VTF phối hợp với Sở VH - TT - DL và Liên đoàn quần vợt Nghệ An NTF tổ chức ; là giải đấu chuyên nghiệp quốc gia lần đầu tiên được tổ chức tại Nghệ An . Ông Nguyễn Quốc Kỳ - PCT kiêm TTK Liên đoàn quần vợt Việt Nam Tham gia giải lần này có 22 VĐV nam , 9 VĐV nữ có điểm xếp hạng cao nhất của bộ môn quần vợt chuyên nghiệp , đến từ các trung tâm quần vợt lớn trong cả nước như : Thành phố Hồ Chí Minh ; Bình Dương ; Hà Nội , Đà Nẵng ... Trong đó , những tên tuổi lớn của làng quần vợt chuyên nghiệp Việt Nam như : Lý Hoàng Nam ; Phạm Minh Tuấn ; Hoàng Thành Trung ; Trịnh Linh Giang ; Trần Thị Tâm Hảo ; Nguyễn Thị Bé Xuyên ... Các VĐV thi đấu ở 4 nội dung gồm : Đơn nam ; đôi nam ; đơn nữ và đôi nữ theo thể thức đấu loại trực tiếp . Giải đấu là dịp để khích lệ phong trào tập luyện môn Tennis trên địa bàn tỉnh , là cơ sở để Nghệ An hướng đến tổ chức những giải đấu lớn của quần vợt chuyên nghiệp Việt Nam trong thời gian tới ; góp phần quảng bá hình ảnh quê hương Nghệ An đến với khán giả cả nước . Phát biểu tại lễ khai mạc , ông Huỳnh Thanh Điền - Phó Chủ tịch UBND tỉnh Nghệ An khẳng định : Giải quần vợt các cây vợt xuất sắc Việt Nam Cúp Vietravel 2016 lần đầu tiên được tổ chức tại Nghệ An là bước tiến mới của phong trào phát triển môn quần vợt tại tỉnh Nghệ An . Đây là dịp để góp phần quảng bá hình ảnh quê hương Chủ tịch Hồ Chí Minh đến với khán giả cả nước . Giải đấu cũng là cơ hội rất tốt để Liên đoàn quần vợt Nghệ An (NTF) nâng cao vị thế của mình trong làng quần vợt cả nước . Giải Quần vợt các cây vợt xuất sắc Việt Nam Cúp Vietravel 2016 khởi tranh vòng đấu bảng vào ngày 5-10 / 12 tại sân CLB Trường Sơn , TP Vinh . Tổng giá trị tiền thưởng lên tới trên 300 triệu đồng . Dịp này , Ban tổ chức giải đã trao 10 triệu đồng ủng hộ Trung tâm bảo trợ xã hội tỉnh Nghệ An . Nguyễn Duy

- Nhan cua van ban dau tien: Giải trí

2.1 Tiền xử lý dữ liệu đưa dữ liệu từ dạng text về dạng ma trận

- Thử nghiệm để kiểm tra hoạt động chuyển hoá dữ liệu về dạng ma trận

```
[15]: # load dữ liệu các stopwords
with open("data/vietnamese-stopwords.txt",encoding="utf8") as f:
    stopwords = f.readlines()
stopwords = [x.strip().replace(" ", "_") for x in stopwords]
print("Danh sách 10 từ dừng đầu tiên (từ không mang ý nghĩa phân loại): ",
      stopwords[:10])
print()

#
# Transforming data
# Chuyển hoá dữ liệu text về dạng vector tfidf
# - loại bỏ từ dừng
# - sinh từ điển
module_count_vector = CountVectorizer(stop_words=stopwords)
model_rf_preprocess = Pipeline([('vect', module_count_vector),
                                 ('tfidf', TfidfTransformer()),
                                 ])

# Hàm thực hiện chuyển đổi dữ liệu text thành dữ liệu số dạng ma trận
# Input: Dữ liệu 2 chiều dạng numpy.array, mảng nhãn id dạng numpy.array

# Tiền xử lý với Bag of words
data_bow = module_count_vector.fit_transform(data_train.data, data_train.target)
# Tiền xử lý với TF-IDF
data_tfidf = model_rf_preprocess.fit_transform(data_train.data, data_train.
      target)

print("10 từ đầu tiên trong từ điển:\n")
i = 0
for k,v in module_count_vector.vocabulary_.items():
    i+=1
    print(i, ": ", (k, v))
    if i > 10:
        break
print()
```

Danh sách 10 từ dừng đầu tiên (từ không mang ý nghĩa phân loại): ['a_lô', 'a_ha', 'ai', 'ai_ai', 'ai_nấy', 'ai_đó', 'alô', 'amen', 'anh', 'anh_ấy']

10 từ đầu tiên trong từ điển:

```
1 : ('dân_trí', 1910)
2 : ('12', 31)
```

```

3 : ('giải', 2248)
4 : ('quần_vợt', 5047)
5 : ('tay_vợt', 5655)
6 : ('xuất_sắc', 7201)
7 : ('việt_nam', 6947)
8 : ('cúp', 1574)
9 : ('vietravel', 6912)
10 : ('2016', 124)
11 : ('chính_thức', 1196)

```

2.2 Chia dữ liệu làm 2 phần training và testing

- Training chiếm 80 % dữ liệu
- Testing chiếm 20 % dữ liệu

```

[16]: from sklearn.model_selection import train_test_split

# chia dữ liệu thành 2 phần sử dụng hàm train_test_split.
test_size = 0.2
# Bow
X_train_bow, X_test_bow, y_train_bow, y_test_bow = train_test_split(data_bow,
    ↪data_train.target, test_size=test_size, random_state=30)
# Tf-idf
X_train_tfidf, X_test_tfidf, y_train_tfidf, y_test_tfidf =
    ↪train_test_split(data_tfidf, data_train.target, test_size=test_size,
    ↪random_state=30)

# hiển thị một số thông tin về dữ liệu
print("Dữ liệu training = ", X_train_bow.shape, y_train_bow.shape)
print("Dữ liệu testing = ", X_test_bow.shape, y_test_bow.shape)

print()
print("Danh sách nhãn và id tương ứng: ", [(idx, name) for idx, name in
    ↪enumerate(data_train.target_names)] )

```

Dữ liệu training = (179, 7972) (179,)

Dữ liệu testing = (45, 7972) (45,)

Danh sách nhãn và id tương ứng: [(0, 'Giải trí'), (1, 'Khoa học - Công nghệ'), (2, 'Kinh tế'), (3, 'Pháp luật'), (4, 'Sức khỏe'), (5, 'Thể thao'), (6, 'Thời sự')]

```

[17]: ### bài tập ###
# yêu cầu: Hiển thị ra id, tên nhãn của 5 văn bản đầu tiên trong tập train.
# gợi ý: lấy dữ liệu id từ biến y_train, mapping với thứ tự nằm trong mảng
    ↪data_train.target_names

```

```
#####
# code

print('{:2} | {:45}'.format('ID', 'Label name'))
for i in range(5):
    print('{:2} | {:45}'.format(data_train.target[i], data_train.target_names[i]))

#####
```

```
ID | Label name
5 | Giải trí
5 | Khoa học - Công nghệ
5 | Kinh tế
5 | Pháp luật
5 | Sức khỏe
```

2.3 Training Naive Bayes model

Sử dụng thư viện sklearn để xây dựng 2 mô hình - `naive_bayes.MultinomialNB(alpha= 0.1)`: giá trị làm mịn `alpha= 0.1` - `naive_bayes.GaussianNB()`

2.3.1 Multinomial Naive Bayes

- Sử dụng Bag of words

```
[18]: print("- Training ...")

# X_train.shape
print("- Train size = {}".format(X_train_bow.shape))
model_MNB = naive_bayes.MultinomialNB(alpha= 0.1)
model_MNB.fit(X_train_bow, y_train_bow)

print("- model_MNB - train complete")
```

```
- Training ...
- Train size = (179, 7972)
- model_MNB - train complete
```

2.3.2 2.2. Gaussian Naive Bayes

- Sử dụng TF-IDF

```
[19]: ### bài tập ###
# yêu cầu: huấn luyện một mô hình Gaussian Naive Bayes tương tự như trên
# gợi ý: naive_bayes.GaussianNB(var_smoothing=1e-3)
#####
# code
```

```

print("- Training ...")

# X_train.shape
print("- Train size = {}".format(X_train_tfidf.shape))

model_GNB = naive_bayes.GaussianNB(var_smoothing=1e-3)
model_GNB.fit(X_train_tfidf.toarray(), y_train_tfidf)

print("- model_GNB - train complete")
#####

```

```

- Training ...
- Train size = (179, 7972)
- model_GNB - train complete

```

2.4 Testing Naive Bayes model

Thực hiện dự đoán nhãn cho từng văn bản trong tập test

Độ đo đánh giá: $\text{accuracy} = \frac{\text{tổng số văn bản dự đoán đúng}}{\text{tổng số văn bản có trong tập test}}$

```

[20]: # Sử dụng thư viện tính accuracy_score trong sklearn
from sklearn.metrics import accuracy_score

```

```

[21]: print("- Testing ...")
y_pred_bow = model_MNB.predict(X_test_bow)
print("- Acc = {}".format(accuracy_score(y_test_bow, y_pred_bow)))

```

```

- Testing ...
- Acc = 0.9555555555555556

```

```

[22]: #Test tương tự cho GNB?
print("- Testing ...")
y_pred_tfidf = model_GNB.predict(X_test_tfidf.toarray())
print("- Acc = {}".format(accuracy_score(y_test_tfidf, y_pred_tfidf)))

```

```

- Testing ...
- Acc = 0.9555555555555556

```

2.5 5. Thực hiện sử dụng model đã được train để infer 1 văn bản mới

- Dữ liệu mới đến ở dạng dữ liệu thô => cần tiền xử lý dữ liệu về dạng dữ_liệu_ma_trận
- infer sử dụng hàm model.predict(dữ_liệu_ma_trận)

```

[23]: a = ViTokenizer.tokenize("Trường đại học bách khoa hà nội")
print(a)

```

Trường đại_học bách_khoa hà_nội

```
[24]: # tiền xử lý dữ liệu sử dụng module module_count_vector.
van_ban_moi = ViTokenizer.tokenize("Công Phượng ghi bàn cho đội tuyển Việt Nam")
#van_ban_moi = ["Công_phượng ghi_bàn cho_đội_tuyển Việt_nam"]
print(van_ban_moi)
input_data_preprocessed = module_count_vector.transform([van_ban_moi])
print(input_data_preprocessed)

print()
print("Danh sách nhãn và id tương ứng: ", [(idx, name) for idx, name in
→enumerate(data_train.target_names)] )
```

Công Phượng ghi_bàn cho_đội_tuyển Việt_Nam

(0, 1538)	1
(0, 2177)	1
(0, 4837)	1
(0, 6947)	1
(0, 7877)	1

Danh sách nhãn và id tương ứng: [(0, 'Giải trí'), (1, 'Khoa học - Công nghệ'), (2, 'Kinh tế'), (3, 'Pháp luật'), (4, 'Sức khỏe'), (5, 'Thể thao'), (6, 'Thời sự')]

```
[30]: ### bài tập ###
# yêu cầu: dự đoán nhãn của 1 văn bản mới. Sử dụng mô hình Multinomial NB
# gợi ý: thực hiện code suy diễn mô hình từ tiền xử lý (bước 1) => infer (bước
→4). (Chú ý: không training lại - ko gọi lại hàm fit.)
#####
# code

y_pred = model_MNB.predict(input_data_preprocessed)
print(y_pred, data_train.target_names[y_pred[0]])

#####
```

[5] Thể thao

2.6 Quan sát độ chính xác trên tập test của GNB khi thay đổi tham số var_smoothing

```
[34]: # code #####

var_smoothings = [1e-1, 1e-2, 1e-3, 1e-4, 1e-5]
accs = []

for var_smoothing in var_smoothings:
```

```

model_GNB = naive_bayes.GaussianNB(var_smoothing=1e-3)
model_GNB.fit(X_train_tfidf.toarray(), y_train_tfidf)

#Hoàn thiện thêm phần code ở đây để ghi nhận acc tương ứng trong từng trường hợp
→hợp
y_pred_tfidf = model_GNB.predict(X_test_tfidf.toarray())
acc = accuracy_score(y_test_tfidf, y_pred_tfidf)
accs.append(acc)

#Minh họa tương quan bằng đồ thị::
#Gợi ý: barplot, lineplot, ...

import seaborn as sns
sns.lineplot(x=var_smoothings, y = accs)

#####


for i in range(len(accs)):
    print(var_smoothings[i], accs[i])

```

```

0.1 0.9555555555555556
0.01 0.9555555555555556
0.001 0.9555555555555556
0.0001 0.9555555555555556
1e-05 0.9555555555555556

```



[]: